

**Решение физических задач.
Физически информированные нейронные сети.
Нейронные ОДУ**

Юлия Мороз, Дмитрий Загоруля

20 февраля 2026 г

1 Решение ДУ численными методами

2 Нейронные ОДУ

- Что это?
- Neural ODEs as a discovery tool to characterize the structure of the hot galactic wind of M82
- Deep Neural Networks for Modeling Astrophysical Nuclear Reacting Flows
- Проблемы

3 Физически информированные нейронные сети

- Как все исправить

Состояние $z(t)$ подчиняется уравнению:

$$\frac{d}{dt}z(t) := f(t, z(t), \theta)$$

решение при заданных начальных условиях:

$$\begin{aligned} z(t_1) &= z(t_0) + \int_{t_0}^{t_1} f(t, z(t), \theta) dt = \\ &= \text{ODESolve}(z(t_0), f(t, z(t), \theta)) \end{aligned}$$

$f(\cdot)$ – векторное поле, θ – параметры.

Численные методы решения?




Рис.: Пример использования метода Эйлера (1)

- Метод Эйлера

$$z(t + \Delta t) = z(t) + \Delta t f(t, z(t), \theta)$$

Состояние $z(t)$ подчиняется уравнению:

$$\frac{d}{dt}z(t) := f(t, z(t), \theta)$$

решение при заданных начальных условиях:

$$\begin{aligned} z(t_1) &= z(t_0) + \int_{t_0}^{t_1} f(t, z(t), \theta) dt = \\ &= \text{ODESolve}(z(t_0), f(t, z(t), \theta)) \end{aligned}$$

$f(\cdot)$ – векторное поле, θ – параметры.




Рис.: Пример использования метода Эйлера (1)

- Метод Эйлера

$$z(t + \Delta t) = z(t) + \Delta t f(t, z(t), \theta)$$

Состояние $z(t)$ подчиняется уравнению:

$$\frac{d}{dt}z(t) := f(t, z(t), \theta)$$

решение при заданных начальных условиях:

$$\begin{aligned} z(t_1) &= z(t_0) + \int_{t_0}^{t_1} f(t, z(t), \theta) dt = \\ &= \text{ODESolve}(z(t_0), f(t, z(t), \theta)) \end{aligned}$$

$f(\cdot)$ – векторное поле, θ – параметры.

- Метод Рунге-Кутты (RK4)

$$z(t + \Delta t) = z(t) + \frac{1}{6}\Delta t(k_1 + k_2 + k_3 + k_4)$$

нет набора ДУ,
описывающих
задачу

ДУ известны, но
неизвестны их
параметры

ДУ известны,
но динамика
сложная

Аппроксимируем векторное поле нейронной сетью:

$$\frac{d}{dt}z(t) := f(t, z(t), \theta) \approx NN(t, z(t), \theta_{NN})$$

так, что интегрирование предсказаний НС позволит получить

$$z(t_1) = \text{ODESolve}(z(t_0), t_1, NN(t_0, z(t_0), \theta_{NN}))$$




Рис.: Из первой работы по НОДУ (2)

Нейронные ОДУ. Что это?

Пусть ОДУ не дано, но есть зашумленные наблюдения

вдоль траектории

$$\{(z_i, t_i)\}_i^M$$

так, что интегрирование предсказаний НС позволит получить

$$z(t_1) = \text{ODESolve}(z(t_0), t_1, NN(t_0, z(t_0), \theta_{NN}))$$

Как построить функцию потерь?

$$L = L(z(t_1), \hat{z}(t_1, \theta_{NN}))$$

Как ее оптимизировать?




Рис.: Автор: [github.msurtsukov](https://github.com/msurtsukov)

Минимизация потерь




Рис.: Иллюстрация из оригинальной статьи (2)

Потери:

$$L = L(z(t_1), \hat{z}(t_1, \theta_{NN}))$$

как оптимизировать?

- 1 метод обратного распространения ошибки
- 2 предложенный авторами оптимизированный метод (torchdiffeq)

Пример

Галактический ветер Messier 82: классический подход

Моделирование гидродинамики:

$$\frac{(A\rho v)_x}{A} = \dot{\mu}, \quad vv_x = -\frac{P_x}{\rho} - \nabla\Phi - \frac{\dot{\mu}v}{\rho}$$
$$v\epsilon_x - \frac{vP\rho_x}{\rho^2} = -\frac{n^2\Lambda}{\rho} + \frac{\dot{\mu}}{\rho} \left(v^2 - \epsilon - \frac{P}{\rho} \right)$$

x – частная производная 1 порядка по x

v – скорость среды

ρ, P – плотность, давление

ϵ – внутренняя энергия

$\nabla\Phi$ – гравитация

n – концентрация частиц

Λ – скорость охлаждения

A – скорость поверхностного расширения

$\dot{\mu}$ – volumetric mass-loading rate



Рис.: Messier 82: NASA, ESA, and The Hubble Heritage Team (STScI/AURA)





Рис.: Гидродинамический расчет (3) [Preprint], общий вид центральной области моделирования: показаны плотность газа, металличность и температура. Сверху вниз результаты для времени 10 и 20 млн лет.

Галактический ветер M82: оценить приток массы с помощью НС

Для всех x



Идея (4): зададим набор (v_0, P_0, ρ_0) , $\dot{\mu} \approx NN_{\theta}$ и сделаем шаг РК4. С P, ρ оценим энтропию

$$\hat{K} \propto \frac{P}{\rho^{5/3}}$$

- Восстановление $\dot{\mu}$ по данным телескопа Чандра $\{T, \rho\}_i$
- ? Как валидировать метод?
- Синтетический тест для заданного $\dot{\mu}$

Галактический ветер M82: результаты валидации




Рис.: Результаты валидации из работы (4)

Галактический ветер M82: по данным Чандра




Рис.: Восстановление параметров по данным Чандра (4)

Еще один пример, работа (5)

Исходная система уравнений

$$\frac{\partial(\rho X_k)}{\partial t} + \nabla \cdot (\rho X_k \mathbf{v}) = \rho \dot{\omega}_k,$$

$$\frac{\partial(\rho \mathbf{v})}{\partial t} + \nabla \cdot (\rho \mathbf{v} \mathbf{v} + p \mathbf{I}) = 0,$$

$$\frac{\partial(\rho \epsilon)}{\partial t} + \nabla \cdot [\mathbf{v}(\rho \epsilon + p)] = \rho \dot{S}.$$

Можно рассмотреть реакции и гидродинамику независимо

$$\frac{dX}{dt} = \dot{\omega}(T, \rho, X), \quad \frac{d(\rho \epsilon)}{dt} = \rho \dot{S},$$

X_k – относительное содержание ядер k в среде

v – скорость среды

ρ – плотность

ϵ – полная внутренняя энергия

p – давление


$\dot{\omega}$ – скорость реакции

$\dot{S}$ – rate of generation of nuclear energy per unit mass

$$\begin{aligned} \begin{bmatrix} X(t + \Delta t) \\ \epsilon(t + \Delta t) \end{bmatrix} &:= \mathcal{F}(T(\epsilon(t), \rho, X(t)), \rho, X(t)) \\ &= \begin{bmatrix} X(t) + \int_t^{t+\Delta t} \dot{\omega} dt \\ \epsilon(t) + \int_t^{t+\Delta t} \dot{S} dt \end{bmatrix}, \end{aligned}$$

Modeling Astrophysical Nuclear Reacting Flows

Для всех x



- Пользуемся независимостью ДУ
- Генерируем различные ТД состояния (T, ρ, X_k) в свойственных звезде диапазонах
- Шаг интегрирования с РК4: $D_{\text{train}} = \{x_i, u_i\}$
- Обучаем с потерями

$$L_{\text{all}} = L_{\text{data}} + L_{\text{sum}}$$

$$L_{\text{data}} = \frac{1}{N} \sum_{i=1}^N \|u_i - \tilde{u}_i\|_{L_1},$$

$$L_{\text{sum}} = \frac{1}{N} \sum_{i=1}^N \left\| \sum_k^{N_s} \tilde{X}_k^i - 1 \right\|_{L_1}$$

Modeling Astrophysical Nuclear Reacting Flows: результат





Рис.: Сравнение НС (пунктирные кривые) и численного интегрирования (сплошные) из работы (5)

Для всех x

$$x(t) = [T(t), \rho(t), X(t)]$$

$$\frac{(A\rho v)_x}{A} = \frac{P_x}{\rho^2} \frac{\dot{m}v}{\rho} \left(\frac{P}{\rho} \right)$$

$$u(t) = [X(t + \Delta t) - X(t)]$$

$$L_{\text{data}} = \frac{1}{N} \sum_{i=1}^N \|u_i - \tilde{u}_i\|_{L_1},$$

$$L_{\text{sum}} = \frac{1}{N} \sum_{i=1}^N \left\| \sum_k^{N_s} \tilde{X}_k^i - 1 \right\|_{L_1}$$




Рис.: Ускорение для случаев 1D и 2D (5)

Нейронная сеть обучилась, но **какой ценой?**

- приток массы извне в закрытой системе?
- вероятности складываются в 1.5? в 2?
- утечка энергии?

В каких условиях вероятность **галлюцинаций** особенно велика?

Решение: условная оптимизация (оптимизация с ограничениями)




Рис.: (6)

Физически информированные нейронные сети. Основная идея




Рис.: Схема PINN из работы (7). $L_{\text{all}} = L_{\text{problem}} + L_{\text{physics}}$

1. Нейронные ОДУ – полезный инструмент, использование которого зависит **только от вашей фантазии**
2. С нейронными ОДУ можно значительно **ускорить** расчеты
3. ... И восстановить неизвестные параметры
4. Нельзя забывать про физику, для этого есть **PINN**

1. *Numerical Methods. An Inquiry-Based Approach With Python*, <https://numericalmethodssullivan.github.io/index.html>, Accessed: 2026-02-20.
2. R. T. Q. Chen, Y. Rubanova, J. Bettencourt, D. Duvenaud, *Neural Ordinary Differential Equations*, 2019, arXiv: 1806.07366 (cs.LG), (<https://arxiv.org/abs/1806.07366>).
3. T.-R. Wang, W. Zhu, X.-F. Li, W.-S. Hong, L.-L. Feng, *Revisiting the Galactic Winds in M82 I: the recent starburst and launch of outflow in simulations*, 2026, arXiv: 2412.09452 (astro-ph.GA), (<https://arxiv.org/abs/2412.09452>).
4. D. D. Nguyen, Y.-S. Ting, T. A. Thompson, S. Lopez, L. A. Lopez, *Neural ODEs as a discovery tool to characterize the structure of the hot galactic wind of M82*, 2023, arXiv: 2311.02057 (astro-ph.GA), (<https://arxiv.org/abs/2311.02057>).
5. X. Zhang и др., *The Astrophysical Journal* **990**, 105, ISSN: 1538-4357, (<http://dx.doi.org/10.3847/1538-4357/adf331>) (сент. 2025).
6. C. Geniesse и др., *Visualizing Loss Functions as Topological Landscape Profiles*, 2024, arXiv: 2411.12136 (cs.LG), (<https://arxiv.org/abs/2411.12136>).
7. S. Eyama, Y. Masada, *Constraining the Cosmological Constant from Stellar Orbits Around Sgr A* Using Physics-Informed Neural Networks*, 2025, arXiv: 2508.19719 (astro-ph.CO), (<https://arxiv.org/abs/2508.19719>).