

Байесовские методы. Simulation based Inference.

Юлия Мороз, Дмитрий Загоруля

13 марта 2026 г

1 Введение

- Формула Байеса
- Пример 1: редкая болезнь
- Пример 2: парадокс Монти Холла

2 Simulation-based inference

- Neural Posterior Estimation
- Neural Likelihood Estimation
- Neural Ratio Estimation

3 Астрофизические приложения

- Simulation-Based Inference with Neural Posterior Estimation applied to X-ray spectral fitting
- Simulation-Based Inference of the sky-averaged 21-cm signal from CD-EoR with REACH

Основные принципы **классической статистики**: Основные принципы **байесовской статистики**:

- 1 Вероятности относятся к относительной частоте событий.
- 2 Параметры являются фиксированными, неизвестными константами.
- 3 Статистические процедуры должны иметь четко определенные долгосрочные частотные свойства.

- 1 Вероятность описывает степень субъективной уверенности, а не предельную частоту.
- 2 Выводы о параметре делаются путем построения его вероятностного распределения – это распределение количественно оценивает степень неопределенности наших знаний об этом параметре.

Пусть $p(x)$, $p(y)$ – два вероятностных события, тогда для условных вероятностей этих событий выполняется **формула Байеса**

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)} = \frac{p(x|y)p(y)}{\int p(x|y)p(y)dy} = \frac{p(x|y)p(y)}{\sum_{j=1}^M p(x|y_j)p(y_j)}$$

Пример

Редкая болезнь

Пусть существует заболевание с частотой распространения среди населения 0.001 и метод диагностического обследования, который с вероятностью 0.9 выявляет больного, но при этом имеет вероятность 0.01 ложноположительного результата – ошибочного выявления заболевания у здорового человека. Найти вероятность того, что человек здоров, если он был признан больным при обследовании.

Пусть существует заболевание с частотой распространения среди населения 0.001 и метод диагностического обследования, который с вероятностью 0.9 выявляет больного, но при этом имеет вероятность 0.01 ложноположительного результата – ошибочного выявления заболевания у здорового человека. Найти вероятность того, что человек здоров, если он был признан больным при обследовании.

Решение:

Пусть A – событие, что пациент болен, а B – событие, что метод выявляет больного пациента.

Вероятность того, что человек болен: $p(A) = 0.001$, того что здоров: $p(\bar{A}) = 1 - p(A) = 0.999$.

Вероятность того, что метод выявляет болезнь, если человек болен: $p(B|A) = 0.9$, вероятность того, что метод выявляет болезнь, если человек здоров $p(B|\bar{A}) = 0.01$.

Вероятность того, что человек здоров, если он был выявлен больным: $p(\bar{A}|B) \Leftarrow$ **вопрос задачи.**

$$p(B) = p(B|A) \cdot p(A) + p(B|\bar{A}) \cdot p(\bar{A}) = 0.9 \cdot 0.001 + 0.01 \cdot 0.999 = 0.01089$$

$$p(\bar{A}|B) = \frac{p(B|\bar{A}) \cdot p(\bar{A})}{p(B)} = \frac{0.01 \cdot 0.999}{0.01089} \approx 0.917.$$

Ответ: $p(\bar{A}|B) \approx 0.917$.

Пример 2

Парадокс Монти Холла

Представьте, что вы стали участником игры, в которой вам нужно выбрать одну из трёх дверей. За одной из дверей находится автомобиль, за двумя другими дверями – козы. Вы выбираете одну из дверей, например, номер 1, после этого ведущий, который знает, где находится автомобиль, а где – козы, открывает одну из оставшихся дверей, например, номер 3, за которой находится коза. После этого он спрашивает вас – не желаете ли вы изменить свой выбор и выбрать дверь номер 2? Увеличатся ли ваши шансы выиграть автомобиль, если вы примете предложение ведущего и измените свой выбор?

Парадокс Монти Холла

Представьте, что вы стали участником игры, в которой вам нужно выбрать одну из трёх дверей. За одной из дверей находится автомобиль, за двумя другими дверями – козы. Вы выбираете одну из дверей, например, номер 1, после этого **ведущий, который знает, где находится автомобиль, а где – козы**, открывает одну из оставшихся дверей, например, номер 3, за которой находится коза. После этого он спрашивает вас – не желаете ли вы изменить свой выбор и выбрать дверь номер 2? Увеличатся ли ваши шансы выиграть автомобиль, если вы примете предложение ведущего и измените свой выбор?

Решение:

Пусть событие A_i , что машина находится за i -й дверью, а событие B_j , что ведущий открыл j -ю дверь $i \in \overline{1, 3}$, $j \in \overline{1, 3}$.

Пусть мы выбрали 3-ю дверь, а ведущий открыл 2-ю дверь, чему равна вероятность $p(A_1|B_2)$?

$$p(A_1|B_2) = \frac{p(B_2|A_1) \cdot p(A_1)}{p(B_2)}$$

$p(A_1) = p(A_2) = p(A_3) = 1/3$, $p(B_2|A_1) = 1$ (одну дверь выбрали мы, за другой – автомобиль).
 $p(B_2) = p(B_2|A_1) \cdot p(A_1) + p(B_2|A_2) \cdot p(A_2) + p(B_2|A_3) \cdot p(A_3) = (1 + 0 + 1/2) \cdot 1/3 = 1/2$.

Ответ: $p(A_1|B_2) = 2/3$.

Что такое simulation-based inference (SBI)?

“The practice of running simulations in order to estimate parameters”

Байесовская статистика + Нейронные сети

Представим, что у нас есть идеальный симулятор и пары (x, θ) , где x – данные, а θ – параметры. Какие выводы мы можем сделать?

$$p(\theta|x) \propto p(x|\theta)p(\theta),$$



где $p(\theta)$ называют **априорной вероятностью**, $p(x|\theta)$ – **функция правдоподобия**, $p(\theta|x)$ – **апостериорная вероятность**.




Зная (или допуская), априорное распределение $p(\theta)$ и имея симулятор, можно итеративно сделать оценку апостериорного распределения для заданного x_{obs} .

- 1 Берем случайное $\theta \sim p(\theta)$;
- 2 Проводим моделирование для этого θ , получаем $x_{\text{sim}} \sim p(x|\theta)$;
- 3 Если $d(S(x_{\text{sim}}), S(x_{\text{obs}})) < \varepsilon$, где S – некоторая статистика, а $d(\cdot, \cdot)$ – некоторая метрика, то мы получаем одну точку из апостериорного распределения.

⇒ крайне не эффективно по вычислительным ресурсам.

SBI: approximate bayesian computation







В зависимости от того, что нас интересует, выделяют три основных вида SBI:

- 1 Neural Posterior Estimation (NPE);
- 2 Neural Likelihood Estimation (NLE);
- 3 Neural Ratio Estimation (NRE).

Построение вероятностного распределения с НС $P(y|x)$



$$\min_w L = \min_w \sum_{i=0}^N (y_{true,i} - y(x_i))^2$$



Построение вероятностного распределения с НС $P(y|x)$


Если мы принимаем


$$P(y|x) = \mathcal{N}(\mu_y(x), \sigma_y^2(x)) \text{ и } \arg \min_w L = \arg \max_w P(y|x),$$

тогда

$$\min_w L = \min_w \sum_{i=0}^N \log(\sigma_y(x_i)) + \frac{(y_{\text{true},i} - \mu_y(x_i))^2}{2\sigma_y(x_i)^2}$$

parameters





$d(\theta, x) \in [0, 1]$

$$d(\theta, x) = \frac{P(\theta, x)}{P(\theta)P(x) + P(\theta, x)}$$

- $d(\theta, x) = 0 : x, \theta \sim P(\theta)P(x)$
- $d(\theta, x) = 1 : x, \theta \sim P(\theta, x)$

$$\frac{P(x|\theta)}{P(x)} = \frac{d(\theta, x)}{1 - d(\theta, x)}$$

$$P(a|b) = \frac{P(b|a)P(a)}{P(b)}$$

Пример




Рис.: (1)

Пример 2

TRUNCATED MARGINAL NEURAL RATIO ESTIMATION




Рис.: (2)

1. SBI используют, когда модель умеет генерировать данные, но функция правдоподобия $p(x|\theta)$ недоступна или слишком дорого считается.
2. Вместо прямого вычисления функции правдоподобия SBI опирается на симуляции: генерируются пары (θ, x) , и по ним обучается метод инференса.
3. Цель SBI остаётся байесовской: восстановить распределение параметров по наблюдениям, то есть апостериори $p(\theta|x)$, а не просто одну лучшую оценку.
4. Главная сила SBI – возможность работать со сложными реалистичными моделями, а главное ограничение – зависимость качества результата от симулятора, априори и покрытия симуляциями.

Использованные источники

1. D. Barret, S. Dupourqué, *A&A* **686**, A133, arXiv: 2401.06061 (astro-ph.IM) (июнь 2024).
2. A. Saxena, P. D. Meerburg, C. Weniger, E. d. L. Acedo, W. Handley, *RAS Techniques and Instruments* **3**, 724—736, arXiv: 2403.14618 (astro-ph.CO) (январь 2024).