

Доменная адаптация.

Юлия Мороз, Дмитрий Загоруля

17 апреля 2026 г

- 1 Приложение ML в науке
- 2 Доменная адаптация
 - Введение
 - Виды доменных сдвигов
 - Методы доменной адаптации
- 3 Методы визуализации
 - t-SNE
 - Isomap
 - Umap
 - Выравнивание латентного пространства
- 4 Примеры доменной адаптации
 - DA-GNNs for Constraining Cosmological Parameters Across Multiple Data Sets
 - Sinkhorn Dynamic Domain Adaptation

- ❶ Хочу обучить модель, но недостаточно меток заслуживающих доверия?
⇒ **Маленькие размеченные выборки**
- ❷ Хочу обучить модель на симулированных данных, а предсказывать на настоящих?
⇒ **Доменный сдвиг**
- ❸ Насколько хорошо качественно модель будет работать?
⇒ **Оценка неопределенности**
- ❹ Почему модель работает так плохо/хорошо?
⇒ **Интерпретируемость**
- ❺ Могу ли я сравнить свою модель с моделями других ученых?
⇒ **Бенчмарки**

Что это такое?




Рис.: MicroBooNE (1)





Рис.



Почему модель плохо предсказывает?




Рис.: Enter Caption

Source labels?	Target labels?	Setting
YES	YES	Inductive transfer learning / Multi-task learning
NO	YES	Self-taught learning
YES	NO	Domain Adaptation
NO	NO	Unsupervised transfer learning

Таблица: Виды трансфер лернинга в зависимости от наличия меток у доменов.

Source domain

$$D_S = \{(x_i^S, y_i^S)\}_{i=1}^{n_S}$$

где n_S — число размеченных примеров из совместного распределения $P_S(x, y)$

Target domain

$$D_T = \{x_i^T\}_{i=1}^{n_T}$$

где n_T — число неразмеченных примеров из распределения $P_T(x)$

$$P_S(x, y) \neq P_T(x, y)$$

Source domain

$$D_S = \{(x_i^S, y_i^S)\}_{i=1}^{n_S}$$

где n_S — число размеченных примеров из совместного распределения $P_S(x, y)$

Target domain

$$D_T = \{x_i^T\}_{i=1}^{n_T}$$

где n_T — число неразмеченных примеров из распределения $P_T(x)$

$$P_S(x, y) \neq P_T(x, y)$$

Сдвиг меток:

$$P_s(Y) \neq P_t(Y) \quad \text{при} \quad P_s(X | Y) = P_t(X | Y)$$

Условное распределение данных при фиксированной метке остаётся одинаковым, но распределение меток меняется, то есть частоты классов различаются между доменами (например, при дисбалансе классов), в то время как каждый класс “выглядит” одинаково в обоих доменах.

Source domain

$$D_S = \{(x_i^S, y_i^S)\}_{i=1}^{n_S}$$

где n_S — число размеченных примеров из совместного распределения $P_S(x, y)$

Target domain

$$D_T = \{x_i^T\}_{i=1}^{n_T}$$

где n_T — число неразмеченных примеров из распределения $P_T(x)$

$$P_S(x, y) \neq P_T(x, y)$$

Сдвиг концепта:

$$P_s(X) = P_t(X), \quad \text{но} \quad P_s(Y | X) \neq P_t(Y | X)$$

Распределение входных данных остаётся одинаковым, но отображение из входа в метку меняется, то есть один и тот же вход может получать разные метки в разных доменах (например, из-за разных правил разметки или изменения самого понятия класса).

Source domain

$$D_S = \{(x_i^S, y_i^S)\}_{i=1}^{n_S}$$

где n_S — число размеченных примеров из совместного распределения $P_S(x, y)$

Target domain

$$D_T = \{x_i^T\}_{i=1}^{n_T}$$

где n_T — число неразмеченных примеров из распределения $P_T(x)$

$$P_S(x, y) \neq P_T(x, y)$$

Условный сдвиг:

$$P_S(Y) = P_T(Y), \quad \text{но} \quad P_S(X | Y) \neq P_T(X | Y)$$

Распределение меток остаётся одинаковым, но условное распределение входных данных при фиксированной метке меняется, то есть один и тот же класс может соответствовать разным данным в разных доменах (например, из-за различий в измерениях, сенсорах или условиях наблюдения).

Source domain

$$D_S = \{(x_i^S, y_i^S)\}_{i=1}^{n_S}$$

где n_S — число размеченных примеров из совместного распределения $P_S(x, y)$

Target domain

$$D_T = \{x_i^T\}_{i=1}^{n_T}$$

где n_T — число неразмеченных примеров из распределения $P_T(x)$

$$P_S(x, y) \neq P_T(x, y)$$


Ковариативный сдвиг:

$$P_S(X) \neq P_T(X), \quad \text{но} \quad P_S(Y | X) = P_T(Y | X)$$

Распределение данных меняется (часто не только из-за свойств изображений, но и из-за особенностей выборки, например, из-за разных сенсоров или смещения при отборе данных), но условное распределение меток при фиксированных данных остаётся одинаковым.


Domain adversarial neural network

DANN — извлекатель признаков + предсказатель меток + классификатор домена



- **Слой инверсии градиента** — умножает градиент на отрицательную константу во время обратного распространения ошибки.
- Приводит к извлечению **домен-инвариантных признаков**.
- Во время обучения размечены только изображения из исходного домена.

Reconstruction-Based Training




Модель совместно обучает общее представление кодирования для двух задач:


- **классификация** размеченных данных из исходного домена
- **реконструкция** неразмеченных данных из целевого домена

Distance-Based Training


Are P and Q different?




Observe $X = \{x_1, \dots, x_n\} \sim P$



Gaussian kernel on x_i




Gaussian kernel on y_i





$$\hat{\mu}_P(v) := \frac{1}{m} \sum_{i=1}^m k(x_i, v)$$

$\hat{\mu}_Q(v)$: mean embedding of Q




Distance-Based Training




Методы визуализации


t-distributed Stochastic Neighbor Embedding (t-SNE)




Original




Perplexity: 2
Step: 5,000




Perplexity: 5
Step: 5,000



Perplexity: 30
Step: 5,000



Perplexity: 50
Step: 5,000




Perplexity: 100
Step: 5,000

Distill

Isometric Mapping (Isomap)


Isomap – это метод обучения многообразий, который сохраняет глобальную геометрию, вычисляя геодезические расстояния вдоль графа, соединяющего ближайших соседей. Он полезен для выявления скрытой структуры данных, лежащих на нелинейном многообразии.




Uniform Manifold Approximation and Projection (UMAP)

UMAP — это быстрый и масштабируемый нелинейный метод снижения размерности, который сохраняет как локальную, так и частично глобальную структуру, используя нечеткие топологические представления.



Он часто превосходит t-SNE в сохранении глобальных взаимосвязей и лучше подходит для больших наборов данных.



Выравнивание латентного пространства




Выравнивание латентного пространства



Ćiprijanović et al. 2020.
Ćiprijanović et al. 2021.

Domain Adaptation

Up to 30% increase!



Пример 1

Constraining Cosmological Parameters Across Multiple Data Sets




Рис.: (2)

Пример 2

SIDDA: Sinkhorn Dynamic Domain Adaptation

- **Обучаемое масштабирование** функции потерь основной задачи и DA-функции потерь.
- **Обучаемый план Синхорна**, т.е. насколько детализированной должна быть метрика расстояния.
- **Не требуется настройка!**
- До **40% улучшения точности** на неразмеченных данных.




Рис.: (3)

1. C. Adams и др., *Physical Review D* **99**, 092001, arXiv: [1808.07269 \(hep-ex\)](#) (май 2019).
2. A. Roncoli, A. Ćiprijanović, M. Voetberg, F. Villaescusa-Navarro, B. Nord, *Domain Adaptive Graph Neural Networks for Constraining Cosmological Parameters Across Multiple Data Sets*, 2024, arXiv: [2311.01588 \(astro-ph.CO\)](#), (<https://arxiv.org/abs/2311.01588>).
3. S. Pandya, P. Patel, B. D. Nord, M. Walmsley, A. Ciprijanovic, *Machine Learning: Science and Technology*, ISSN: 2632-2153, (<http://dx.doi.org/10.1088/2632-2153/adf701>) (авг. 2025).