Способы оценки неопределенностей в задачах регрессии и классификации

Юлия Мороз, Дмитрий Загоруля

24 апреля 2026 г.

Содержание

1. Какие бывают неопределенности
2. Методы учета ошибок в машинном обучении
   - Регрессия гауссовского процесса (GPR)
   - Simulation Based Inference (SBI)
     - Байесовская нейронная сеть
     - MC dropout
     - Neural Posterior Flow
   - Детерминированные модели
   - Ансамблевые методы
3. Качество оценки неопределеннностей
4. Сравнение методов

Что такое неопределенность?

Для чего нужна оценка неопределенностей?

- уровень доверия – важное свойство статистической оценки
- интерпретируемость моделей
- повышает способность моделей к обобщению
- важно для high-stakes decisions (обеспечение безопасности ML моделей)
- в научных задах: уровень доверя к "открытию"

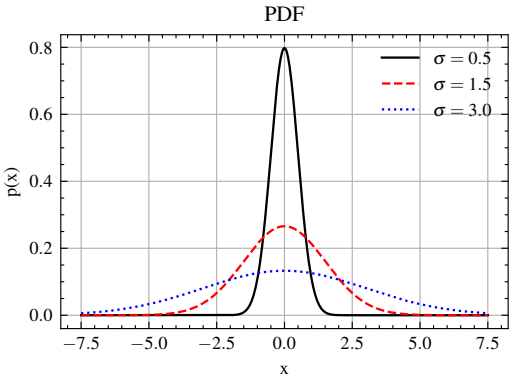


Рис.: Плотность вероятности (PDF) распределения Гаусса

Что такое неопределенность?

Для чего нужна оценка неопределенностей?

- уровень доверия – важное свойство статистической оценки
- интерпретируемость моделей
- повышает способность моделей к обобщению
- важно для high-stakes decisions (обеспечение безопасности ML моделей)
- в научных задах: уровень доверя к "открытию"

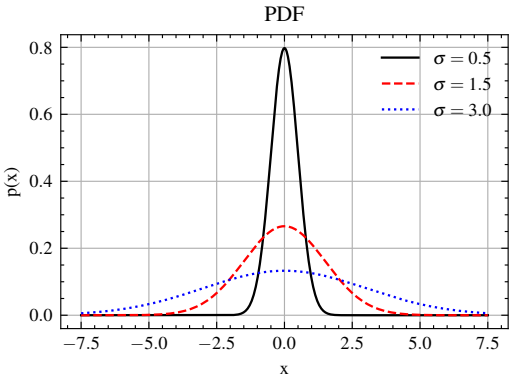


Рис.: Плотность вероятности (PDF) распределения Гаусса

Мотивация

Что такое неопределенность?

Для чего нужна оценка неопределенностей?

- уровень доверия – важное свойство статистической оценки
- интерпретируемость моделей
- повышает способность моделей к обобщению
- важно для high-stakes decisions (обеспечение безопасности ML моделей)
- в научных задах: уровень доверя к "открытию"

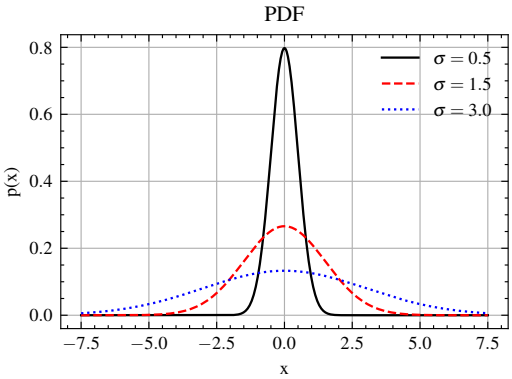


Рис.: Плотность вероятности (PDF) распределения Гаусса

Что такое неопределенность?

Для чего нужна оценка неопределенностей?

- уровень доверия – важное свойство статистической оценки
- интерпретируемость моделей
- повышает способность моделей к обобщению
- важно для high-stakes decisions (обеспечение безопасности ML моделей)
- в научных задах: уровень доверя к "открытию"

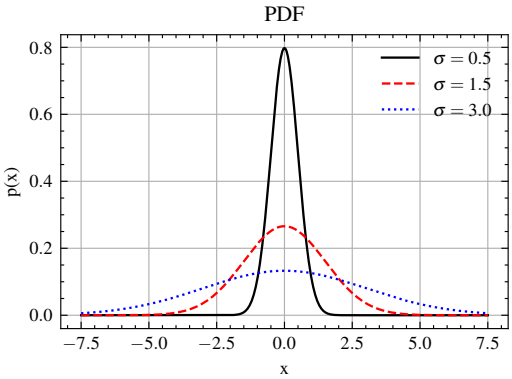


Рис.: Плотность вероятности (PDF) распределения Гаусса

Мотивация

Что такое неопределенность?

Для чего нужна оценка неопределенностей?

- уровень доверия – важное свойство статистической оценки
- интерпретируемость моделей
- повышает способность моделей к обобщению
- важно для high-stakes decisions (обеспечение безопасности ML моделей)
- в научных задах: уровень доверя к "открытию"

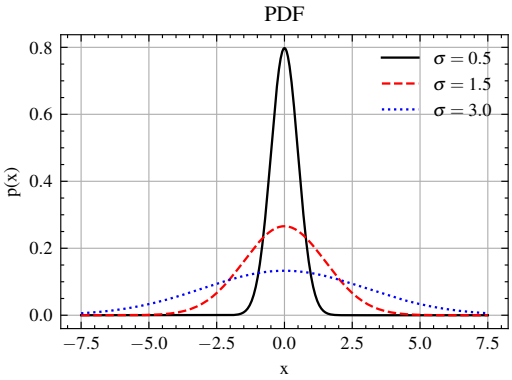


Рис.: Плотность вероятности (PDF) распределения Гаусса

Откуда берутся ошибки?

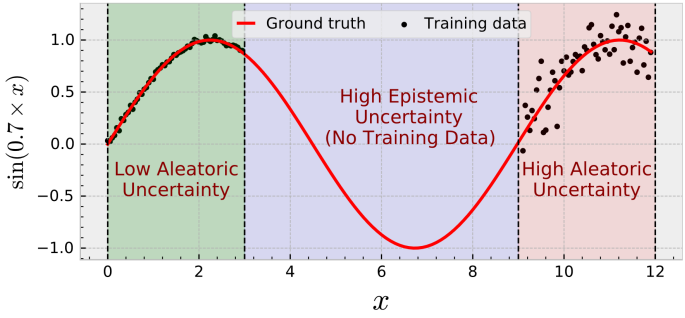


Рис.: Ref. (*1*)

Алеоторная [в данных]

неопределность, обусловленная случайной природой физической системы. Неустранима

Эпистемическая [в модели]

неопределенность, возникающая из-за недостатка знаний о системе

Откуда берутся ошибки?

Алеоторная

- → неопределенность наблюдений [шум]
- → естественная изменчивость
- → недостаочная предсказательная сила [например, неразделимые классы]

Эпистемическая

- → модельная [выбор архитектуры]
- → параметрическая [неуверенность в параметрах]
- → может быть уменьшена
  - расширение тренировочного набора / использование качественных примеров
  - физически-информированные потери / ограничения
  - выбор подходящей модели и процедуры обучения

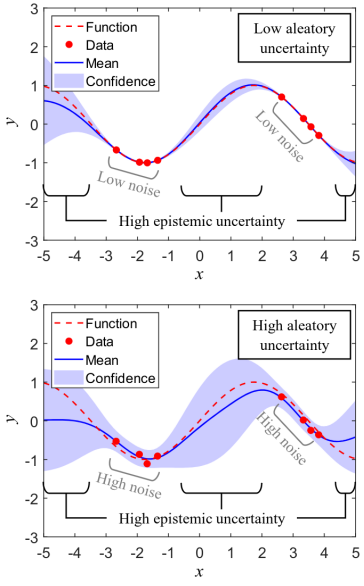
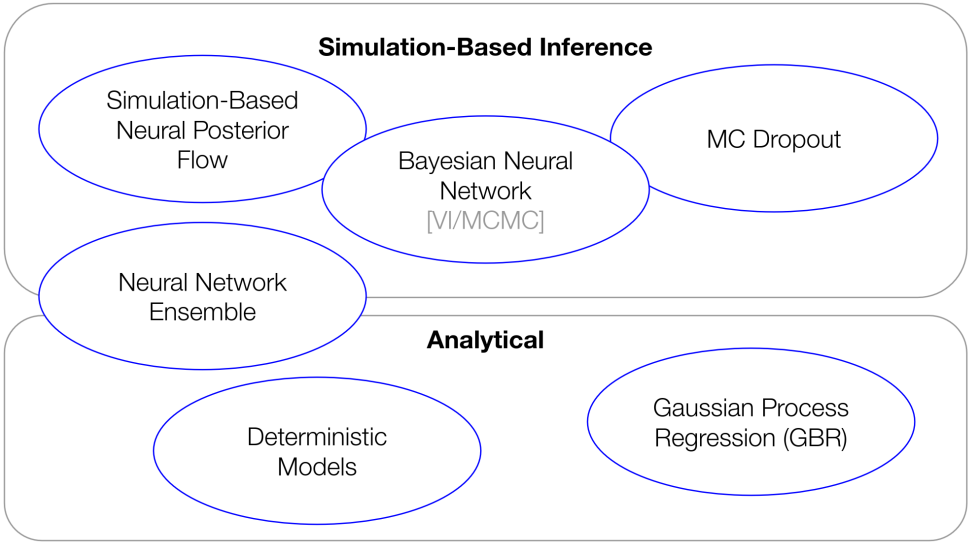


Рис.: Ref. (2)

Методы учета ошибок в машинном обучении



Регрессия гауссовского процесса (GPR)

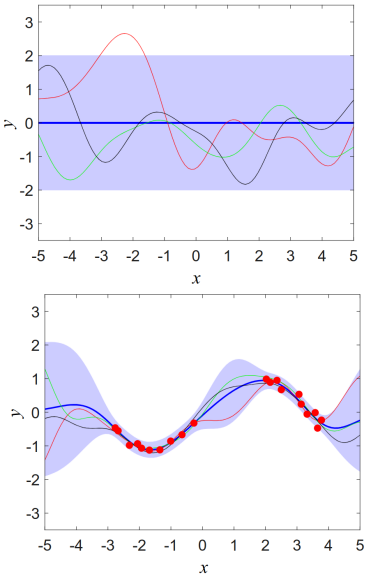


Рис.: Prior and posterior Ref. (*3*)

Предположение: все распределено по Гауссу

$$y_i \sim \mathcal{N}(\mu_i, \sigma_i),\ x_j \sim \mathcal{N}(\mu_j, \sigma_j)$$

Для полного описания: мат. ожидание $m(x)$ и ковариационная функция $k(x, x')$

$$k(x, x') = \sigma^2 \exp\left(-\frac{\|x - x'\|^2}{2l^2}\right)$$

Постериор задан аналитически:

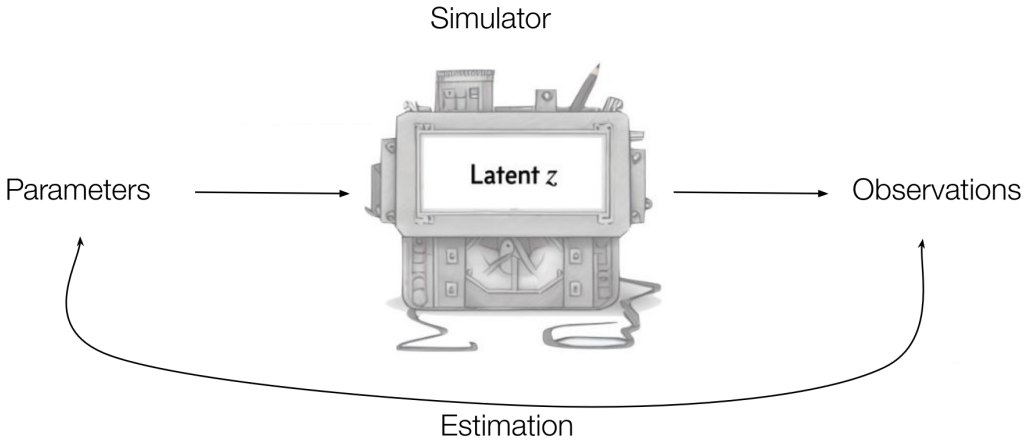
$$p(y_*|\mathcal{D}, x_*)$$

→ точно определяет out-of-distribution (OOD) примеры

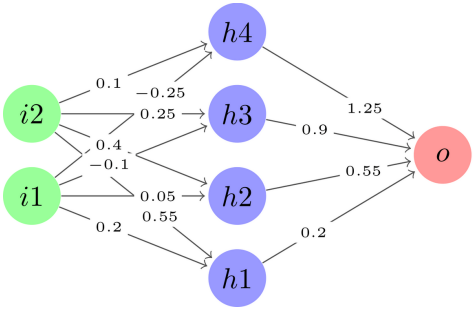
→ сложно масштабируется

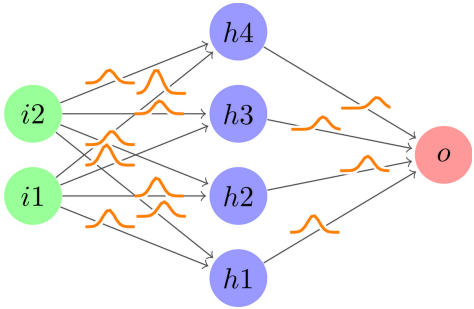
Simulation Based Inference (SBI)

"The practice of running simulations in order to estimate parameters"



SBI: Байесовская нейронная сеть





Вводим неуверенность в параметрах модели $\theta \sim p(\theta)$. Для набора $\mathcal{D} = \{X, y\}$:

$$p(\theta|\mathcal{D}) = \frac{p(\mathcal{D}|\theta)p(\theta)}{p(\mathcal{D})} \propto p(\mathcal{D}|\theta)p(\theta)$$

Разные способы вывода: MCMC, Variational Inference

$\Rightarrow$ можно явно оценить два типа ошибок для конкретного x_*, y_*:

1. $p(\hat{y_*}|x_*, \mathcal{D}) = p(f(x_*; \theta)|x_*, \mathcal{D})$
2. $p(y_*|x_*, \mathcal{D}) = p([f(x_*; \theta) + \varepsilon]|x_*, \mathcal{D})$

SBI: MC dropout

С вероятностью p каждый вес может **обнулиться**

- прост в имплементации
- качество неопределенности зависит от гиперпараметров p и числа слоев с отбрасыванием
- низкая стабильность
- нет сходимости к истинному постериору

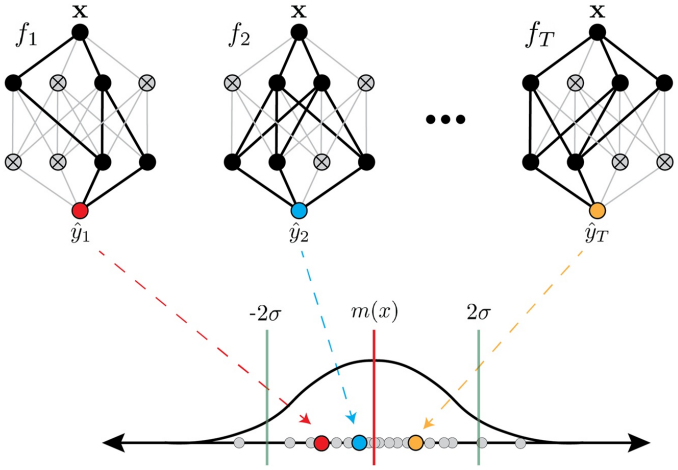


Рис.: красивая картинка из ref. (*4*)

Алеоторная неопределенность для сложных постериоров – обратимая НС:

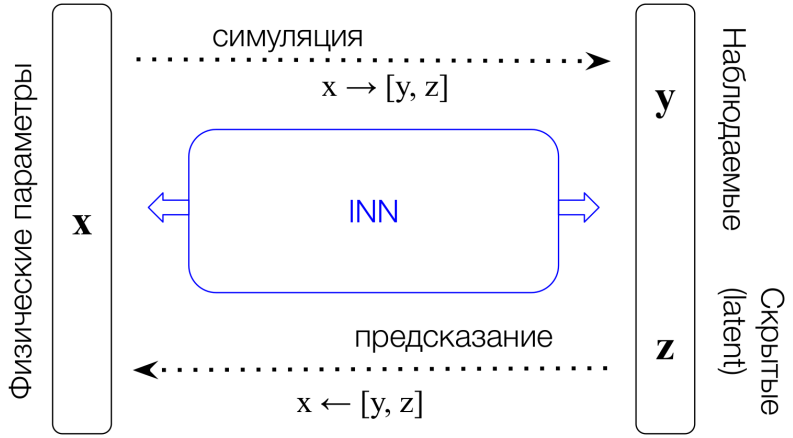
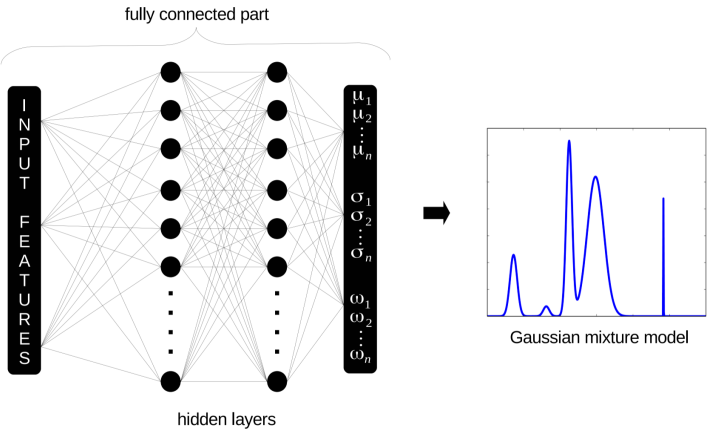


Рис.: Схема ОНС: вывод $p(y|x)$ на основе симуляций

Детерминированные модели



Функция потерь – правдоподобие или другая мера качества CDF/PDF

$\longrightarrow$ только алеоторная неопределенность

Рис.: Пример архитектуры, оценивающей алеоторную неопределенность

Ансамблевые методы

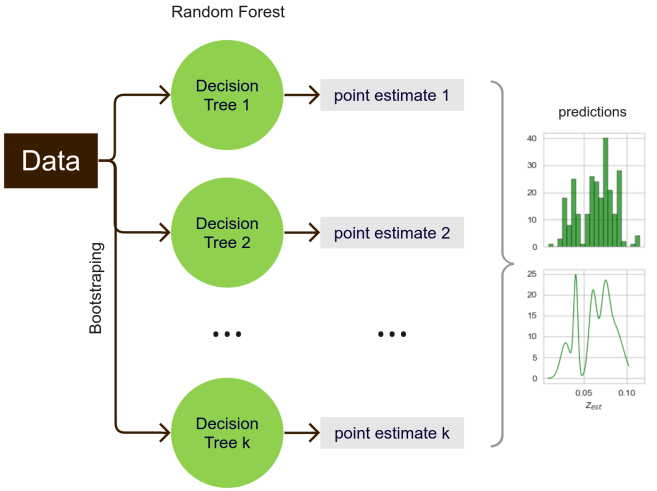


Рис.: Пример архитектуры, оценивающей эпистемическую неопределенность

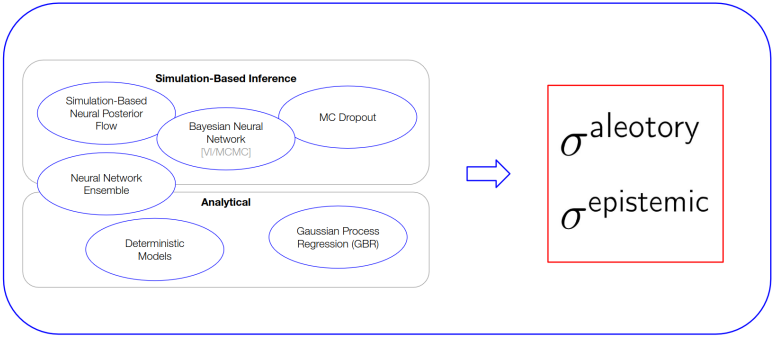
Идея

обучить несколько моделей и оценить разброс оценок

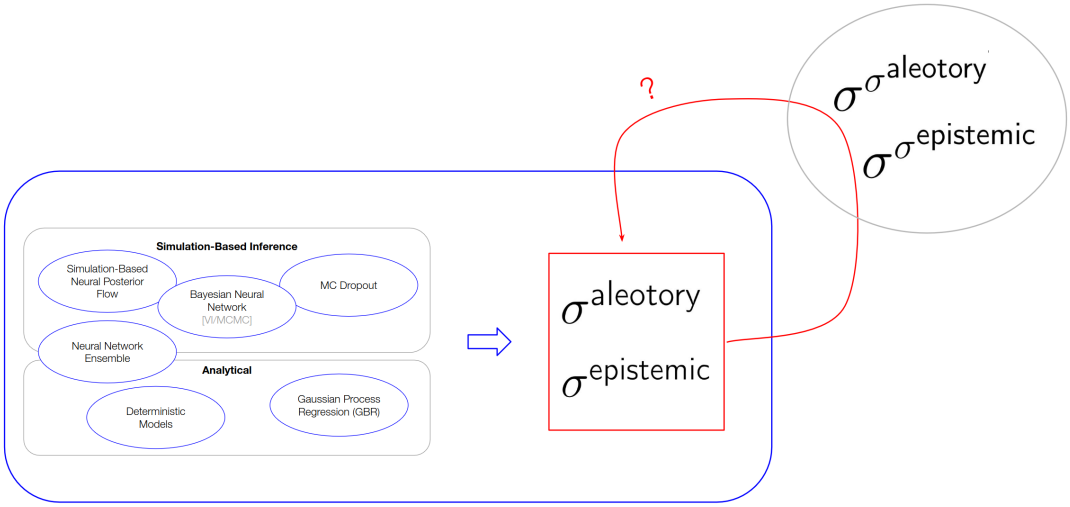
$\longrightarrow$ оценка эпистемической неопределенности

$\longrightarrow$ можно оценивать разброс для отдельного примера σ_i, получится комбинированная неопределенность

Как оценить качество полученных неопределенностей?



Как оценить качество полученных неопределенностей?



Пример 1. Калибровочные кривые: задачи классификации

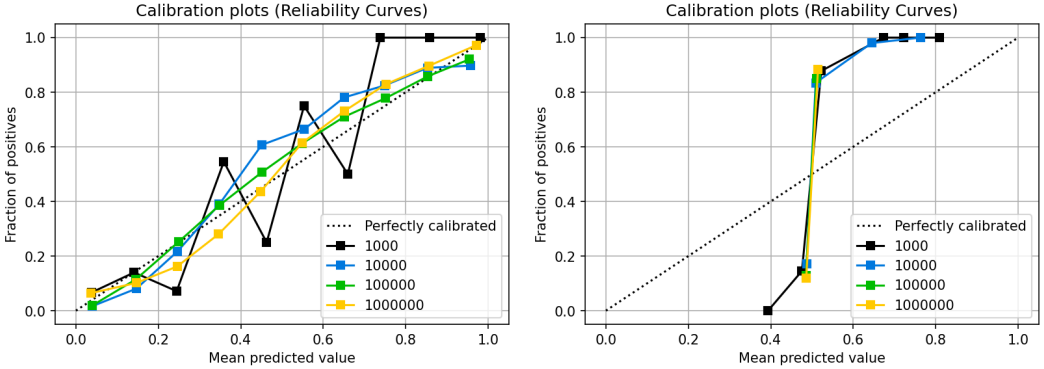


Рис.: Mean predicted – вероятность 1 класса на выходе классификатора. Fraction of positives – истинная доля 1 класса для примеров с такой вероятностью

Пример 1. Калибровочные кривые: задачи регрессии

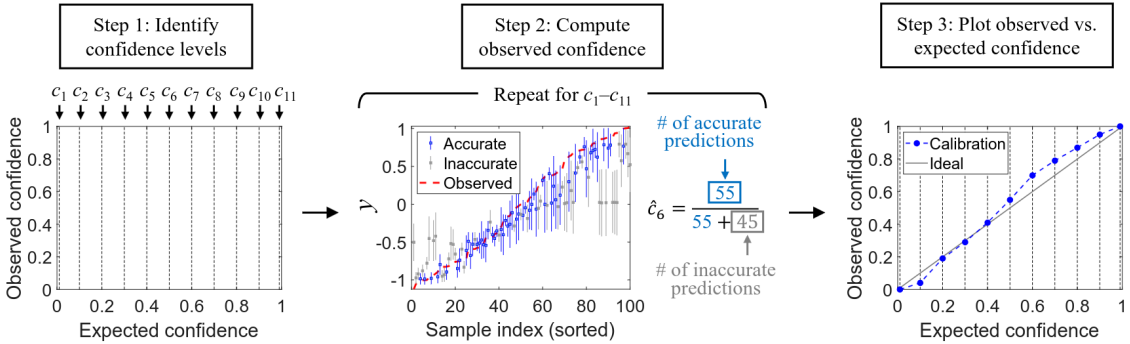
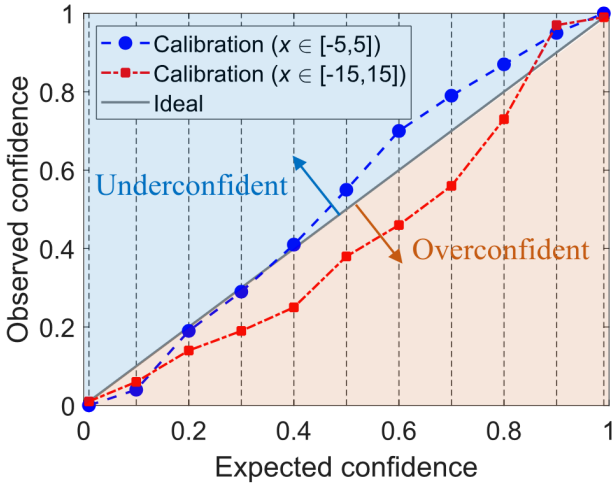


Рис.: Процедура построения калибровочной кривой в задаче регрессии. Идея: оценить частоту попадания y_i в предсказанный дов. интервал $\hat{\sigma}_i$ (частота должна соответствовать уровню доверия), ref. (3)

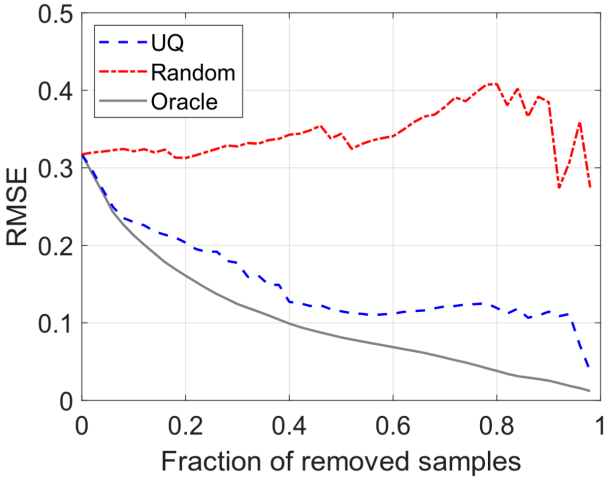
Калибровочные кривые: интерпретация



- недостаток уверенности модели в оценке примеров: там, где модель должна давать 0.5, она предсказывает 0.8 (точнее)
- избыток уверенности модели: там, где модель должна давать 0.5, предсказывает 0.2 (менее точно, завышает уверенность)

Разреживание (sparsification plots and metrics)

- → сортировка примеров: от большой неопределенности к малой
- → последовательное удаление из выборки примеров с большим разбросом
- → расчет точности (RMSE или др.)
- → визуальное сравнение



Другие способы

1. Probability Integral Transform – распределение для явных CDF[a]
2. Negative Log-likelihood для явных PDF

$$\log \hat{p}(y_{\text{obs}}|x, \mathcal{D})$$

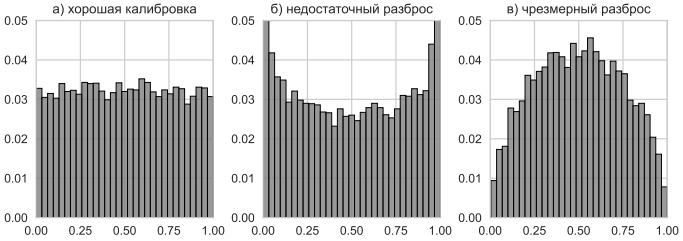
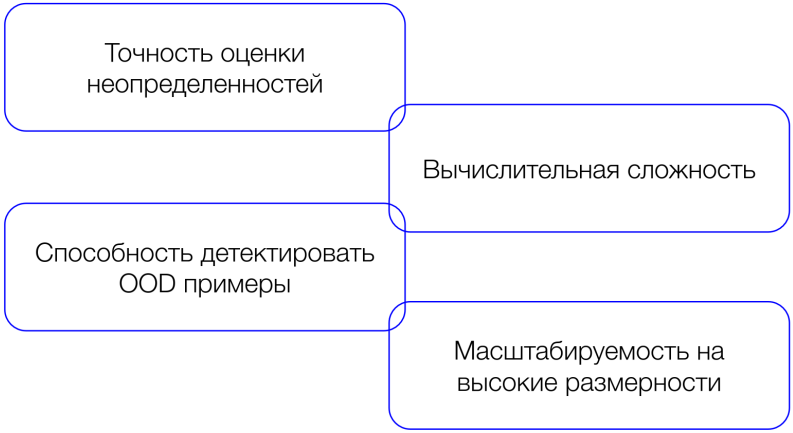


Рис.: Гистограмма PIT $p_t = \hat{F}_{\text{estim}}(x_{\text{obs}})$.

[a] например, $\mathcal{N}(\mu_i, \sigma_i)$

Как выбрать?



*OOD – out-of-distribution

Свойства моделей

Таблица: Сравнение различных способов оценки неопределенности

Свойство	**GPR**	**SBI**			**Ансамбли**	**Детер-минированные**
		BNN	MC dropout	NPE Flow		NPE/NLE
Точность оценки неопределенности	▲	▲	▲	▲	▲	▲
Вычислительная эффективность						
Чувствительность к OOD примерам	▲	▲	▲	▲	▲	▲
Масштабируемость						
Различает алеоторную и эпистимическую неопределенность	Да	Да	Нет	Нет	Да	Нет

▲ Высокая ▲ Выше среднего ▲ Средняя ▲ Низкая

Свойства моделей

Таблица: Сравнение различных способов оценки неопределенности

Свойство	**GPR**	**SBI**			**Ансамбли**	**Детер-минированные**
		BNN	MC dropout	NPE Flow		NPE/NLE
Точность оценки неопределенности	▲	▲	▲	▲	▲	▲
Вычислительная эффективность	▲	▲	▲	▲	▲	▲
Чувствительность к OOD примерам	▲	▲	▲	▲	▲	▲
Масштабируемость	▲	▲	▲	▲	▲	▲
Различает алеоторную и эпистимическую неопределенность	Да	Да	Нет	Нет	Да	Нет

▲ Высокая ▲ Выше среднего ▲ Средняя ▲ Низкая

Messages to take home

1. Существует два типа неопределенностей с разной природой: алеоторная и эпистемическая
2. Для оценки неопределенностей существуют разные методы, самый обширный класс - вывод на основе симуляций (SBI)
3. Нужно оценивать точность построенных оценок неопределенности, особенно при high-stakes decisions
4. У существующих методов разные свойства. Нужно выбирать под свои задачи

Использованные источники

1. O. F. Tuna, F. O. Catak, M. T. Eskil, *Closeness and Uncertainty Aware Adversarial Examples Detection in Adversarial Machine Learning*, 2021, arXiv: 2012.06390 (cs.LG), (https://arxiv.org/abs/2012.06390).
2. A. Thelen *и др.*, *A Comprehensive Review of Digital Twin – Part 2: Roles of Uncertainty Quantification and Optimization, a Battery Digital Twin, and Perspectives*, авг. 2022.
3. V. Nemani *и др.*, *Mechanical Systems and Signal Processing* **205**, 110796, ISSN: 0888-3270, (http://dx.doi.org/10.1016/j.ymssp.2023.110796) (дек. 2023).
4. P. Van Katwyk, B. Fox-Kemper, H. Seroussi, S. Nowicki, K. Bergen, *Journal of Advances in Modeling Earth Systems* **15** (дек. 2023).