

Методы интерпретации моделей машинного обучения.

Юлия Мороз, Дмитрий Загоруля

8 мая 2026 г

- 1 Введение
- 2 Feature Importance
- 3 LIME
- 4 Gradient-based методы
- 5 Сравнение методов
- 6 Современные направления
- 7 Литература

Почему интерпретируемость важна?

- Современные ML-модели часто являются “черными ящиками”
- В астрономии ошибки интерпретации могут приводить к:
 - ложным физическим выводам,
 - selection bias,
 - обнаружению артефактов вместо сигналов.
- Интерпретация нужна для:
 - доверия к модели,
 - поиска систематик,
 - объяснения научных результатов,
 - генерации новых гипотез.

Главный вопрос

На что именно смотрит модель?

- Классификация галактик
- Поиск транзиентов
- Детекция экзопланет
- Морфология AGN jets
- Анализ спектров
- Cosmology surrogate models

Типичные проблемы:

- модель использует шум,
- PSF артефакты,
- calibration leakage,
- correlations вместо physics.




Рис.: Пример astronomical image classification

Идея

Оценить вклад каждого признака в предсказание модели.

Популярные методы:

- Permutation importance
- Gain importance (XGBoost, LightGBM)
- SHAP values
- Random forest feature importance

$$\text{Importance}(j) = \text{Performance}_{\text{original}} - \text{Performance}_{\text{permuted}(j)}$$

Permutation Importance

Алгоритм:

- 1 Обучаем модель
- 2 Перемешиваем один признак
- 3 Измеряем падение качества
- 4 Чем сильнее падение — тем важнее признак

Преимущества:

- model-agnostic
- простая реализация

Недостатки:

- плохо работает с коррелированными признаками
- дорогой computationally

Feature Importance в астрономии

- Photometric redshift estimation
- Stellar classification
- AGN detection
- Cosmological parameter inference

Feature	Importance
Radio flux	0.31
Spectral index	0.24
Redshift	0.18
Jet length	0.12
Noise estimate	0.05

Таблица: Пример importance scores

Проблема корреляций

Если два признака сильно коррелированы:

- importance может “размазаться”,
- физически важный параметр может казаться незначимым.

Основная идея

Аппроксимировать сложную модель простой локальной моделью около конкретного объекта.

$$f(x) \approx g(x)$$

где:

- $f(x)$ — сложная модель,
- $g(x)$ — простая интерпретируемая модель.

Обычно:


- линейная регрессия,
- decision tree.

Как работает LIME

- 1 Выбираем объект
- 2 Генерируем perturbations
- 3 Получаем predictions модели
- 4 Взвешиваем по расстоянию
- 5 Обучаем локальную линейную модель



(a) Исходное изображение



(c) Алгоритм LIME

LIME для изображений

Для изображений:


- image $\rightarrow$ superpixels
- скрываем части изображения
- смотрим изменение prediction

Результат:

- выделение областей,
- наиболее влияющих на prediction.




(a) Original Image



(b) Explaining *Electric guitar*



(c) Explaining *Acoustic guitar*



(d) Explaining *Labrador*

- Galaxy morphology classification
- Supernova detection
- AGN classification
- Gravitational lensing

Пример

Модель классифицирует галактику как spiral.

LIME показывает:

- модель использует spiral arms,
- а не background noise.

- Нестабильность explanations
- Зависимость от perturbations
- Локальная линейность может быть неверной
- Высокая variance

Важно

LIME объясняет поведение модели локально, а не глобально.

Идея

Использовать градиенты модели по входу:

$$\frac{\partial y}{\partial x}$$

Градиенты показывают:

- какие пиксели наиболее важны,
- как изменение входа влияет на output.

Популярные методы:

- Saliency maps
- Guided Backpropagation
- Integrated Gradients
- Grad-CAM

$$S(x) = \left| \frac{\partial y}{\partial x} \right|$$

Интерпретация:

- большие значения $\Rightarrow$ пиксель важен,
- маленькие значения $\Rightarrow$ пиксель почти не влияет.

Плюсы:

- fast,
- simple.

Минусы:

- noisy.




Рис.: Saliency map

$$IG_i(x) = (x_i - x'_i) \int_0^1 \frac{\partial F(x' + \alpha(x - x'))}{\partial x_i} d\alpha$$

Где:

- x' — baseline,
- x — input image.

Преимущества:

- меньше noise,
- satisfies completeness axiom,
- theoretically grounded.

Использует:

- gradients,
- feature maps CNN.

Позволяет:

- визуализировать regions of interest,
- понимать spatial attention модели.

Особенно популярен в:

- astronomy imaging,
- medical imaging.

Grad-CAM




Рис.: Grad-CAM visualization

- Radio galaxy classification
- Fast radio burst detection
- Exoplanet transit analysis
- AGN jet morphology


Пример

Grad-CAM показывает, что CNN:

- действительно использует jet structure,
- а не calibration artifacts.

Опасности gradient explanations

- Sensitive to noise
- Adversarial instability
- Saturation problem
- Gradient shattering



Метод	Local	Global	Для CNN
Feature Importance	+	+	-
LIME	+	-	+
Saliency Maps	+	-	+
Grad-CAM	+	-	++
Integrated Gradients	+	-	+

Практика

Лучше использовать несколько методов одновременно.

- Не доверять одному explanation
- Проверять стабильность
- Использовать domain knowledge
- Сравнивать разные методы
- Искать data leakage

Важно

Интерпретация модели $\neq$ физическая причинность.

Активные направления:

- Explainable Foundation Models
- Physics-informed explanations
- Causal interpretability
- Concept bottleneck models
- Self-explaining neural networks

Особенно важно для:

- LSST,
- SKA,
- Euclid,
- Roman Space Telescope.

- Интерпретируемость критически важна в AstroML
- Feature importance полезен для tabular data
- LIME даёт локальные explanations
- Gradient-based методы особенно эффективны для CNN
- Интерпретация помогает находить систематики и physics

Главная идея

Explainability — инструмент научного анализа, а не только debugging.

- [1] Ribeiro et al., "Why Should I Trust You? Explaining the Predictions of Any Classifier", KDD, 2016.
- [2] Selvaraju et al., "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization", ICCV, 2017.
- [3] Sundararajan et al., "Axiomatic Attribution for Deep Networks", ICML, 2017.
- [4] Ntampaka et al., "The Role of Machine Learning in the Next Decade of Cosmology", BAAS, 2019.
- [5] Molnar, "Interpretable Machine Learning", 2022.
- [6] Lundberg and Lee, "A Unified Approach to Interpreting Model Predictions", NeurIPS, 2017.
- [7] Zhou et al., "Learning Deep Features for Discriminative Localization", CVPR, 2016.